


Relatório de RNA - Aprox. de Funções

1. Arquivo 2




Modelo 1:
Loss: 0.06138618136715973
Iterações: 6430
Layers: 2
Iterações: 10000
Função de ativação: relu
Solver: adam
Learning rate: adaptive
Iterações sem melhora: 500

Modelo 2:
Loss: 0.06141115553651364
Iterações: 1000
Layers: (10, 5)
Iterações: 1000
Função de ativação: relu
Solver: adam
Learning rate: adaptive
Iterações sem melhora: 500

Modelo 3:
Loss: 0.06151783922045739
Iterações: 1000
Layers: (10, 5)
Iterações: 1000
Função de ativação: relu
Solver: adam
Learning rate: adaptive
Iterações sem melhora: 500

- Média losses: 8.05718290175407
- Desvio padrão dos losses: 11.276862151134571

2. Arquivo 3




Modelo 1:
Loss: 0.28578728104993717
Iterações: 9154
Layers: (15, 10, 5)
Iterações: 10000
Função de ativação: relu
Solver: adam
Learning rate: adaptive
Iterações sem melhora: 1000

Modelo 2:
Loss: 0.2861422725449219
Iterações: 3055
Layers: (15, 10, 5)
Iterações: 10000
Função de ativação: relu
Solver: adam
Learning rate: adaptive
Iterações sem melhora: 1000

Modelo 3:
Loss: 0.2967620729712748
Iterações: 2705
Layers: (15, 10, 5)
Iterações: 10000
Função de ativação: relu
Solver: adam
Learning rate: adaptive
Iterações sem melhora: 1000

- **Média losses:** 70.13983453308025
- **Desvio padrão dos losses:** 82.4508115449485

3. Arquivo 4




Modelo 1:
Loss: 6.469827129569128
Iterações: 10000
Layers: (15, 10, 5)
Iterações: 10000
Função de ativação: relu
Solver: adam
Learning rate: adaptive
Iterações sem melhora: 500

Modelo 2:
Loss: 7.301353354748249
Iterações: 10000
Layers: (15, 10, 5)
Iterações: 10000
Função de ativação: relu
Solver: adam
Learning rate: adaptive
Iterações sem melhora: 500


Modelo 3:
Loss: 17.371665377123392
Iterações: 10000
Layers: (15, 10, 5)
Iterações: 10000
Função de ativação: relu
Solver: adam
Learning rate: adaptive
Iterações sem melhora: 500

- **Média losses:** 2670.234249171345
- **Desvio padrão dos losses:** 1659.8295833544166


4. Arquivo 5



Modelo 1:
Loss: 0.00037547772618144856
Iterações: 15000
Layers: (120, 60, 40)
Iterações: 15000
Função de ativação: tanh
Solver: adam
Learning rate: adaptive
Iterações sem melhora: 15000



Modelo 2:
Loss: 0.0003876333946142781
Iterações: 15000
Layers: (120, 60, 40)
Iterações: 15000
Função de ativação: tanh
Solver: adam
Learning rate: adaptive
Iterações sem melhora: 15000



Modelo 3:
Loss: 0.0004205955236095798
Iterações: 15000
Layers: (120, 60, 40)
Iterações: 15000
Função de ativação: tanh
Solver: adam
Learning rate: adaptive
Iterações sem melhora: 15000

- **Média losses:** 0.0004428949354928222
- **Desvio padrão dos losses:** 4.732355753916863e-05

Conclusão

A análise dos resultados evidencia que o modelo aplicado ao Arquivo 5 apresentou o melhor desempenho em termos de aproximação, com uma média de erro extremamente baixa e desvio padrão insignificante. Isso indica alta precisão e estabilidade na aproximação da função correspondente.

Por outro lado, o Arquivo 4 apresentou os piores resultados, com média de perdas muito elevada e grande variabilidade, sugerindo dificuldades na convergência ou inadequação do modelo à função-alvo. Os arquivos 2 e 3 tiveram desempenhos intermediários, sendo o Arquivo 2 significativamente mais estável e preciso do que o 3.

Esses resultados reforçam a importância de uma boa escolha de arquitetura de RNA e de características do conjunto de dados para alcançar aproximações eficientes e confiáveis.